

平成22年度 学士論文

# 非集中型クラウドストレージの スケーラビリティ評価

東京工業大学 理学部 情報科学科

学籍番号 07-0615-4

奥寺 昇平

指導教員

首藤 一幸 准教授

平成23年2月7日

# 概要

Amazon Dynamo、Apache Cassandraをはじめとした、単一故障点がなく、負荷が自動的に分散される非集中型のクラウドストレージが普及しつつある。このような非集中なクラウドストレージにおいて、任意のノードからデータを保持する担当ノードにリクエストを到達させるためには、各ノードが他のノードを把握する必要がある。特に、クライアントが接続したノードから担当ノードに直接リクエストを送るクラウドストレージでは、全ノードがシステム全体の最新の状態を保持する必要があり、システムの整合性を保つことが難しい。

そこで、gossip プロトコルをベースとしたメンバーシップ管理を行うプロトコルが取り入れられ、効率よく通信を行うことが可能である。

一方、このようなメンバーシップ管理もスケーラビリティを制約する要因の一つとなりうる。この管理方法では、すべてのノードで定期的に通信が発生するので、ノード数が増えるにつれ、総通信量が増えるのである。よって、フロントエンド (例えばストレージであれば、データの読み書き処理) の処理効率つまり、アベイラビリティを下げると考えられる。しかしながら、非集中型クラウドストレージにおいて、この管理を行う処理がどれくらいの通信負荷をもたらすのかといったことは知られていない。

そこで本研究では、gossip プロトコルを用いる Cassandra を対象として、ノード数に応じてシステム全体の通信負荷がどのように変化するかを計測・考察する。計測の結果、システム全体で発生する通信量は、ノード数を  $n$  としたとき、 $O(n^2)$  で増加することを確認した。またクラスタ設計時に、gossip プロトコルベースのメンバーシップ管理による通信量を見積もることができる。特に2つのデータセンターをまたぐリンクにおいて  $O(n^2)$  で通信量が増加し、単純な gossip プロトコルではスケーラビリティの制約になりかねないことがわかった。

# 謝辞

本論文を作成にあたり指導を賜りました、指導教員の首藤一幸先生に深謝致します。また、実験、文章構成について熱心に議論にお付き合い頂いた中村俊介さん、長尾洋也さんに感謝の意を表します。同期の宮尾武裕さん、建部大輔さん、互いに支え合いながら卒業論文を完成させることができました。ありがとうございます。最後に、私を陰ながら支えてくれている家族、彼女、そして多くの友人達に感謝の意を表します。

# 目次

<b>第 1 章 序論</b>	<b>6</b>
1.1 本研究の背景 . . . . .	6
1.2 本研究の目的 . . . . .	7
1.3 本研究の成果 . . . . .	7
1.4 本論文の構成 . . . . .	8
<b>第 2 章 研究背景</b>	<b>9</b>
2.1 分散システムにおけるスケーラビリティの確保とスケール アウト . . . . .	9
2.2 故障検知の代表的プロトコル gossip プロトコルとその問題点	10
<b>第 3 章 関連研究</b>	<b>11</b>
3.1 CLON . . . . .	11
3.2 JetStream . . . . .	11
3.3 CREW: A Gossip-based Flash-Dissemination System . . .	12
<b>第 4 章 gossip プロトコル</b>	<b>13</b>
4.1 故障検知とは . . . . .	13
4.2 大規模分散環境における gossip プロトコル . . . . .	18
4.3 Scuttlebutt . . . . .	19
<b>第 5 章 Cassandra について</b>	<b>22</b>
5.1 Cassandra の概要 . . . . .	22
5.1.1 メンバーシップ管理 . . . . .	22
<b>第 6 章 Cassandra の軽量化と測定手法</b>	<b>23</b>
6.1 Cassandra の軽量化 . . . . .	23
6.1.1 プログラムの改変 . . . . .	23
6.1.2 設定ファイルのパラメータ調整 . . . . .	24
6.2 測定手法 . . . . .	24
6.2.1 実験 1:gossip の通信量の測定 . . . . .	24
6.2.2 実験 2:データ読み書きの通信量の測定 . . . . .	25
6.2.3 計測方法について . . . . .	25

6.2.4	通信量の推定 . . . . .	30
6.3	通信量測定のためのプログラムの作成 . . . . .	35
6.3.1	実験環境 . . . . .	35
<b>第 7 章</b>	<b>実験・評価</b>	<b>39</b>
7.1	予備実験 . . . . .	39
7.1.1	予備実験 (1) gossip の通信量推定の妥当性 . . . . .	39
7.1.2	予備実験 (2) :データ読み書き通信量推定の妥当性 . . . . .	40
7.1.3	予備実験 (3) :リクエスト量に応じたデータ読み書き通信量の増加 . . . . .	41
7.2	本実験 . . . . .	42
7.2.1	実験 1:gossip の通信量 . . . . .	42
7.2.2	実験 2:データ読み書き通信量の測定 . . . . .	43
7.3	評価 . . . . .	47
7.3.1	gossip の通信量の見積もり . . . . .	47
7.3.2	1 ノードあたりの通信量 . . . . .	47
7.3.3	複数のデータセンターをまたぐクラスタにおける gossip プロトコルの問題点 . . . . .	47
<b>第 8 章</b>	<b>結論</b>	<b>50</b>
8.1	まとめ . . . . .	50
8.2	今後の課題 . . . . .	50

## 目 次

4.1	gossip プロトコル . . . . .	19
6.1	リソース制限変更前 . . . . .	26
6.2	リソース制限変更後 . . . . .	27
6.3	ifconfig の実行結果 . . . . .	28
6.4	Cassandra クラスタを構成したときの様子 . . . . .	29
6.5	tcpdump の実行結果 . . . . .	30
6.6	gossip 通信量の推定 . . . . .	32
6.7	データ通信量の推定 ～gossip の通信を含む～ . . . . .	33
6.8	データ通信量の推定 ～gossip の通信を含まず～ . . . . .	34
6.9	データ通信量の推定 ～gossip の通信を含む～ . . . . .	37
6.10	データ通信量の推定 ～gossip の通信を含まず～ . . . . .	37
6.11	実行スクリプト . . . . .	38
7.1	マシン台数に応じた gossip の通信量の時間変化 . . . . .	40
7.2	マシン台数別のデータ読み書きの通信量推定値 . . . . .	41
7.3	リクエスト量に応じたデータ読み書き通信量の増加 . . . . .	42
7.4	ノード数別の gossip 通信量の時間変化 . . . . .	44
7.5	ノード数に応じた gossip 通信量の増加 . . . . .	45
7.6	qps 一定時のノード数に応じたデータ読み書き通信量の変化 . . . . .	46
7.7	二つのデータセンターをまたぐクラスタの構成 . . . . .	48

# 第1章 序論

## 1.1 本研究の背景

近年、ネットワークを通じて計算資源を利用するクラウドコンピューティングが重要性を増している。その中でも、Google Storage for Developers [12]、Amazon S3 [13] や Windows Azure ストレージ [14] をはじめとしたペタバイト級の大量のデータを保存するストレージタイプのクラウドに注目が集まる。

クラウドストレージの必要要件として、1) サービスを安定的に提供すること、2) 増加し続ける大量のデータを効率よく処理することの2つが挙げられる。1) サービスを安定的に継続するためには、システムの一部が故障を起こしても、システムの外部から故障を隠蔽し、正常に動作するように振舞わなければならない。一方、クラウドのように大量のノードで構成されるシステムにおいて故障は常である。そこで、故障が起きている状況をあらかじめ想定したシステムが必要である。2) 増加し続ける大量のデータを効率よく処理するためには、ノードの台数に応じてスループットがスケールアウトできるアーキテクチャを採用することが必要である。

そこで、特に注目を集めているのが、Amazon Dynamo [9]、Apache Cassandra [3] をはじめとした非集中型クラウドストレージである。非集中型クラウドストレージとは、構成するすべてのノードが対等の機能をもつクラウドストレージのことである。非集中型クラウドストレージの一つ目の大きな利点は、単一故障点がないことである。単一故障点がないとは、ある部位が故障するとシステム全体が故障してしまうような部位が存在しないことである。非集中型クラウドストレージにはこのような部位はなく、安定したサービスを提供することにつながる。二つ目は、負荷が自動的に分散されることである。これはスケールアウトできるアーキテクチャであることを指している。その一方で、メンバーシップ管理などを各ノードが行う必要がある。

このような非集中なクラウドストレージにおいて、任意のノードからデータを保持する担当ノードにリクエストを到達させる (以後、ルーティングと呼ぶ) ためには、各ノードが他のノードを把握する必要がある。ルーティングの方針として大きく分けて、2つのパターンがある。担当ノードにリクエストを到達させるまでに、別のノードを経由させることを認める

かどうかである。前者のルーティング方式をマルチホップ、後者をシングルホップと呼ぶ。特に、シングルホップ方式のクラウドストレージでは、全ノードがシステム全体の最新の状態を保持する必要がある、整合性を保つことが難しい。例えば、もし古い情報をもとにルーティングを行い、誤って別のノードにリクエストを送信した場合、リクエストは適切に処理されないことになる。そこで、gossip プロトコルをベースとしたメンバーシップ管理を行うプロトコルが取り入れられ、全ノードがシステム全体の最新の状態を保持することが可能である。gossip プロトコルとは、ソーシャルネットワーク で見られる噂 (ゴシップ) の伝搬をモデルとしたアルゴリズムである。

## 1.2 本研究の目的

非集中型クラウドストレージにて gossip プロトコルをベースとしたメンバーシップ管理を行うプロトコルが取り入れられ、全ノードがシステム全体の最新の状態を保持することが可能である。

一方、このようなメンバーシップ管理もスケーラビリティを制約する要因の一つとなりうる。つまり、すべてのノードで定期的に通信が発生するのでノード台数が増えるにつれ通信量が増加するのである。よって、ストレージのフロントエンドの処理である read/write 処理効率つまり、アベイラビリティを下げると思われる。

しかしながら、非集中型のクラウドストレージにおいて、この管理を行う処理がどれくらいの通信負荷をもたらすのかといったことは知られていない。そこで本研究では、gossip プロトコルを用いる Cassandra を対象として、ノード数に応じてシステム全体の通信負荷がどのように変化するかを計測・考察する。

## 1.3 本研究の成果

gossip プロトコル を用いる Cassandra を対象として、ノード数に応じたシステム全体の通信量を計測した。その結果、ノード数を  $n$  として通信量は  $O(n^2)$  で増加することがわかった。またクラスタ設計時に、gossip プロトコルベースのメンバーシップ管理による通信量を見積もることができる。特に2つのデータセンターをまたぐリンクにおいて  $O(n^2)$  で通信量が増加し、単純な gossip プロトコルではスケーラビリティの制約になりかねないことがわかった。



## 1.4 本論文の構成

本論文の残りは、次のような構成からなっている。

第2章は 研究背景として分散システムのアベイラビリティを確保するための故障検知の重要性について説明する。

第3章では、関連研究として gossip プロトコルを応用したマルチキャストやブロードキャストの提案・評価を行った論文を挙げる。

第4章では、gossip プロトコルとその応用である Scuttlebutt について説明する。

第5章では、実験で使用する Cassandra について説明する。

第6章では、Cassandra の軽量化と通信測定の手法を説明する。

第7章では、実験とその評価を行う。

第8章では、結論としてまとめと今後の課題を述べる。

## 第2章 研究背景

### 2.1 分散システムにおけるスケーラビリティの確保とスケールアウト

分散システムには高い可用性が必要とされる。特にクラウドのような大規模な環境においては、急激に増加する負荷やネットワーク分断や部分故障といった問題に対しても迅速に対応し、常に稼動し続けるような安定性・信頼性が求められる。

分散システムの可用性を確保する戦略 [1] としてスケールアップ、スケールアウトの二つがある。スケールアップとはシステムを構成する各マシン(の CPU やメモリ) の高機能化、高性能化を図ることで、システム全体の性能をスケールさせることを目的とした戦略である。従来はこの戦略でシステムの性能向上を図ってきたが、費用に見合った性能向上には限界がある。

一方、スケールアウトとは、マシン一台あたりの性能を上げるのではなく、安価な商用マシンを並べて並列処理を行うことで、可用性を確保するという戦略である。スケールアウトでは、一台あたりのマシンが安いいため、スケールアップ戦略をとった場合と比べ費用を押さえて高い性能を引き出すことができる。しかし、スケールアウトのスケーラビリティ確保の戦略では、マシンの数が増加するほど、システムを構成するマシンやスイッチなどのハードウェアが故障を起こす確率は増加する。つまりシステム全体での平均故障間隔 (MTBF) が非常に短くなってしまう。そこで、ハードウェアは常に故障するということを前提としたシステムの設計が必要となる。

## 2.2 故障検知の代表的プロトコル gossip プロトコルとその問題点

故障検知とは、故障したマシンに接続する他のマシンから故障を検知する仕組みである。またシステムの整合性を保つためには、各マシンが故障したマシンを検知するだけでなく、検知した情報を伝搬しあうことでシステム全体としての合意を取らなければならない。故障検知を行う代表的な手段に gossip プロトコルを応用する方法がある。gossip プロトコルとは、ソーシャルネットワークで見られる噂 (ゴシップ) の伝搬をモデルとしたアルゴリズムである。gossip プロトコルを利用して故障の情報を他のマシンに効率よく伝達することが可能である。一方で、特にクラウドストレージにおいては故障検知によるネットワークや CPU などのリソース消費を控えなければならない。なぜなら、クラウドストレージにおけるメインタスクはクライアントからのデータの読み書きリクエストを処理することであり、故障検知はサブのタスクに過ぎないからである。メインタスクの効率を圧迫するようリソースの消費は許されない。すなわち、CPU サイクルや使用するネットワークバンド幅が限られている環境で故障検知が実現されることが求められているのである。これらの問題を解決するために gossip プロトコルを応用したさまざまなプロトコルが提案されている。

## 第3章 関連研究

本研究の関連研究を紹介する。

### 3.1 CLON

この論文 [2] では、クラウド環境で gossip プロトコルをベースにしたマルチキャストを提案し、その評価を行っている。一般にグローバルで接続されたデータセンターの上で構成されるクラウドの計算環境では、コストが高く、リソース制約があるリンクが存在する。基本的な gossip プロトコルは、信頼性のあるデータ伝搬に対してスケールする一方で、このようなクラウド環境においてはその冗長性から、リンクとノードで高いリソース消費を起こしてしまう。そこで著者は、局所的なリンクを優先するオーバレイを構築し情報の伝搬を行うことで、制約のあるリンク間でのトラフィックを減少させた。

本研究との関連は、分散システムで実ノードを立ち上げ、gossip プロトコルベースのアルゴリズムを通信量の観点から評価しているところである。また gossip プロトコルの問題点として、データセンターをまたぐ通信が考慮されていないことを指摘していることである。本研究との違いは、我々は非集中なクラウドストレージに焦点を当てていること、さらに評価の対象がマルチキャストと故障検知で異なる点である。

### 3.2 JetStream

この論文 [11] の著者は、単純な gossip プロトコルはランダムにノードを選択して通信するために、いくつかのノードでメッセージ受信のオーバーヘッドを引き起こすことになる旨を指摘する。そこで、単純なソーシャルネットワークの規則をアルゴリズムに埋め込むことで、各ノードが情報を伝播する相手を効率よく選択できるようにした。その結果、メッセージ受信のオーバーヘッドをアーカイブできると同時に、情報伝搬の遅延の抑制ならびにシステム全体のネットワーク通信量を減少を実現した。

CLON と同様に、システム全体の通信量を評価しているところが本研究との関連である。本研究との違いは、この論文が gossip プロトコル一

般に議論しているのに対して、我々は故障検知のみに焦点を当てていることである。

### 3.3 CREW: A Gossip-based Flash-Dissemination System

この論文 [10] では、伝搬遅延が少なく効率の良い gossip プロトコルベースのブロードキャストを提案している。

本研究との関連は、ノード台数に応じた gossip 通信量のスケーラビリティについて評価していることである。本研究との主な違いは、この論文が一般の P2P アーキテクチャについて議論をしている一方で、我々は非集中なクラウドストレージに焦点を当てていることである。

## 第4章 gossip プロトコル

本研究の主な対象である gossip プロトコルについて詳しく説明する。まず、故障検知における gossip プロトコルの位置づけを整理する。次に、gossip プロトコルをベースにした情報共有プロトコルである Scuttlebutt について説明する。

### 4.1 故障検知とは

以下論文 [4] で述べられている故障検知の定義と分類基準について紹介する。まず、故障検知の定義を述べる。故障検知とは故障しているノードについての情報を集めるプロセスのことであり、故障が疑わしきノードと、モニターしているノードのリストを管理している。リストは、スタティック、ダイナミックの二つがあり得る。ダイナミックなリストは、絶えず変化するノード群を管理していることである。ネットワークの激しい変化に対しての対応能力を考慮すると、もっと現実的なモデルといえる。一方でスタティックなリストは予め決められたノードだけを管理する。

故障検知はハートビートと Ping の2種類の生存確認メッセージを使って、故障しているノードを判断する。

- ハートビート

ハートビートは、モニターしているプロセスから故障検知を行うプロセスに定期的を送られてくるメッセージのことである。このメッセージで対象ノードが故障していないことを知らせる。もしハートビートが制限時間内に届かなければ、故障検知を行うプロセスは故障していると判断する。

- Ping

Ping は、故障検知を行うプロセスからモニターしているノードに継続的に送られるメッセージのことである。故障検知を行うプロセスは、その応答として Ack を受け取る準備をしている。もし Ack を受け取れなければ、一定時間ごとにメッセージを送るなどで精密な調査を行い、プロセスが本当に故障しているかどうかを確認する。

実際はメッセージ到達の遅延は予測することはできないので、非同期的な環境下で故障しているノードと健全なノードを見分けるのは困難である。よって、故障検知の問い合わせに対して返答がないプロセスは「故障が疑わしきもの」として扱われる。

次に、大規模環境での故障検知を分類するための基準を考える。以下のような分類の切り口が挙げられる。

- A. 集中型 vs. 分散型
- Pull 型 vs. Push 型
- C. アクティブ vs. パッシブ
- D. ベースライン vs. シェアリング
- E. 適応可能な値 vs. 一定の値
- F. グローバル時刻 vs. ローカル時刻
- G. モニターパターン
- H. 故障の伝搬

**A. 集中型 vs. 分散型** 集中型の故障検知は、単体で一枚岩的なモジュールであり、様々なプロセスをモニターすることが可能である。集中型の長所は管理コストが低いこと、欠点は単一故障点が存在し、潜在的なボトルネックとなりやすいことである。一方で分散型の特徴は、これらの欠点がない。分散型は、一連の故障検知モジュール群とみなされていて、各モジュールにシステムの中で異なるプロセスが割り当てられている。リクエストが来るとすぐに、各モジュールが故障が疑わしいノードのリストを提供する。

**Pull 型 vs. Push 型** 生存確認メッセージの受け渡しに関して、Pull 型と Push 型の二つに分類できる。Push 型アプローチでは、ハートビートを用いており、制御フローと情報フローの方向は同じである。一方、Pull 型の故障検知はこのフローは逆である。Pull 型の故障検知においては、Ping メッセージが使われる。ハートビートは、Ping 故障検知と比較して半分のメッセージのやりとりしか必要ないこと、タイムアウト遅延の見積もりが片道のメッセージで判断が出来ることから、アドバンテージがあると考えられる。Ping 故障検知のアドバンテージの一つは、時間の制御が故障検知をおこなうプロセスにおいてだけ実行されることである。

**C. アクティブ vs. パッシブ** 情報を伝搬する際にアプリケーションを利用するかどうかで故障検知を分類できる。アクティブなプロトコルは、生存確認メッセージを継続して送信、受信する。パッシブなプロトコルは、アプリケーションメッセージを利用して故障検知を行う。もしデータ通信が頻繁に発生するならば、故障検知は十分であると言える。一方でパッシブプロトコルが適切でない状況もあり、そうした状況ではアクティブなプロトコルが必要になる。

**D. ベースライン vs. シェアリング** ノードの生存情報について共有するかどうかに関して、ベースラインとシェアリングの二つに分類できる。シェアリングアプローチでは、故障検知するモジュールはモニターしているノードの生存情報について他のモジュールと共有する。ネットワークポロジを考慮して、概して近隣ノード群が使われる。シェアリングアルゴリズムでは、交換される情報の種類、これらが維持する生存確認状態の分量において異なる。ベースラインアプローチでは、それぞれのモジュールが独断で故障が疑われるノードについて判断を下す。

**E. 適応可能な値 vs. 固定の値** 生存確認メッセージの頻度、タイムアウト、その他の時間についての設定を、適応可能な値にするか、固定の値にするかで分類できる。固定の値を採用する利点は、例えば、ノードがシステムに参加したときなどに一度各ノードで計算されるだけであるので実装が容易である。欠点は、ネットワークの激しい変化状況では、効率性は制限されてしまうことである。適応型の故障検知では例えば、タイムアウトの値を調整することで、新しいハートビートの到着時間を予想する。懸念は、こういった値やタイムアウトを計算することは、単純な仕事ではないことである。またいくつかのネットワーク情報を考慮しなければならない。

**F. グローバル時刻 vs. ローカル時刻** 時間に関するその他の事柄は、個々でおこなうか、グローバルに行うかである。単純なアプローチは、すべてのノードに対して、グローバルに生存確認メッセージを出す頻度を利用することである。もしすべてのノードが同質で、同じセッションの存在時間を設けているならばこのアプローチは効果的である。一方、もしノードが同質でないときは、個々のノードがそれぞれがローカル時刻を計算することになる。

その他の分類基準を紹介する前に、我々は大規模環境での故障検知の3つの大きなオペレーション「正常」、「伝搬」、「再設定」について説明する。

- 正常



「正常」フェーズで、故障検知モジュールは生存確認メッセージをモニターするノードに送信する。

- 伝搬  
故障が検知されたときに「伝搬」フェーズがスタートし、故障情報がその他のモジュールに伝えられる。
- 再構成  
「再構成」フェーズは「伝搬」フェーズが終了したときにスタートする。「再構成」フェーズは、ローカルの「再構成」とグローバルの「再構成」の二つフェーズからなる。ローカルの「再構成」は、現存モジュールの故障を修理するときに起きる。例えば、修理が完了するまでグループからこのノードを取り除くことができる。グローバルの「再構成」は、故障情報が他のモジュールに伝搬されたときに起きる。このオペレーションで、他のノードはシステム情報の変化を反映させることができる。

大規模分散環境での故障検知では、モニタリングと伝搬パターンについて二つのパフォーマンス問題が存在する。迅速な伝搬は、システムの整合性を維持するのにつながり、効率的なモニタリングは検知時間を短縮する。

**G. モニターパターン** モニタリングのパターンは、「正常」フェーズにおける故障検知モジュールとモニターしているノードにおけるコミュニケーションに関連がある。モニタリングのパターンには、全対全型、ランダム型、近接ベース型の3つがある。

- 全対全型  
全対全型の故障検知では、各モジュールがすべてのモニターしているプロセスに生存確認メッセージを送信する。構成するグループのメンバーが少ない時、このアプローチは、効率的に機能する。一方で、スケーラビリティは制約される。プロセス数が膨れ上がった時には、大規模ネットワークトラフィックが発生するからである。
- ランダム型  
ランダム型の故障検知では、各メンバーごとに故障検知に使用するためのアドレスと時間のリストを管理している。グループ内の各ノードは、ランダムに他の  $k$  ノードを選択して、生存確認メッセージを送信する。  
gossip プロトコルはハートビートをもとにランダムで故障検知を行う。gossip プロトコルはグループ数が少ないときにはとても効率的である。大規模分散環境のようなグループ数が多い状況をでは、様々

なバリエーションの故障検知が提案されている。大規模分散環境における gossip プロトコルについては、故障検知の分類の後に説明する。モニターしているノード同士でランダムであるいは定期的なコミュニケーションを通じて行われるランダム型の故障検知では、スケーラビリティの改善、検知時間の短縮が可能である。また故障検知時間は、ランダムに選択される確率に依存する。

- 近接ベース型

各プロセスは生存確認メッセージを近隣ノードに送る。局所性を考慮した通信を行うことで、パフォーマンスが改善される。近隣ノードは、故障を検知しない限り時間が経過しても静的で変化しない。一方故障を検知した場合には、故障したノードを除いたり新しい近隣ノードを選択するために「再構成」フェーズが必要になる。またネットワーク情報は考慮されなければならない。

**H. 故障の伝搬** あるノードが故障していると判断されたとき、この情報は他のモジュールに伝搬されなければならない。故障の伝搬は、規模環境では非常に時間がかかるもので、伝搬にかかる時間を短縮するためにさまざまなアプローチが提案されている。全対全、ランダム、リング状の空間、階層構造がある。

- 全対全型の伝搬パターン

全対全型の伝搬パターンの場合、故障は瞬時にすべての故障検知モジュールに伝わる。もし故障やチャーンが頻繁に起こるならば、ネットワーク通信量が一気に跳ね上がってしまう。

- ランダム型の伝搬パターン

ランダム型の伝搬パターンでは、モジュール、モジュール群が選択されて、現存する故障検知モジュールから故障についての情報を受け取る。利点は、全対全伝搬パターンに比べて通信が少なく済むことである。一方、欠点は伝搬にかかる時間が別のノードに選択される割合に依存してしまうことである。

- 円形状の空間の伝搬パターン

円形状の空間の故障検知では、仮想的なリングにノード群を配列する。通信は、近接するノード群だけで行われる。欠点としては、新しいノードが追加されたり、リングからノードが離脱したときには、近接ノードは再構成されなければならないことである。また、仮想的なネットワークトポロジに対して、仮想的なリングをマッピングするのは容易なことではない。また大きなリングにおいて故障の伝搬に非常に時間がかかる。

- 階層構造型の伝搬パターン

階層的な故障検知では、ノード群を複数の階層に配列し、少ないグループのモニタリングに分断する。利点としては、ツリーにそって故障が伝搬していくために、スケーラビリティが改善されることである。また、ネットワークのインフラ事情を考慮に入れることができるので、通信が効率的である。階層的な故障検知は、一般的に大規模分散システムにおいて用いられており、他の伝搬パターンで動作しているスモールグループ同士を連結している。

このような分類基準で故障検知を分類することが可能である。また故障検知における gossip プロトコルの位置づけを整理できた。

## 4.2 大規模分散環境における gossip プロトコル

次に、大規模分散環境での gossip プロトコルの応用について考える。グループ数が少ない時の単純な gossip プロトコルを大規模環境で利用することは、伝搬時間の遅延、通信量の増加などの理由から適切ではなく、改善されなければならない。とくに故障情報の伝播方法に焦点が当てられている。

単純な gossip プロトコルではハートビートで自身の生存を他のノードに知らせているが、ハートビートの際に、他のノードの生存情報を伝播することもできる。この方法には3種類の方法がある。ノード  $P$  とノード  $Q$  の情報伝播について考える。

- Push 型 (図 4.1:左)

Push 型では、ノード  $P$  が持っている情報をノードに知らせノード  $Q$  の情報を更新する。つまりノード  $P$  の更新情報がハートビートとなるのである。

- Pull 型 (図 4.1:中)

Pull 型は Push 型の逆で、ノード  $Q$  が持っている情報を引き出しノード  $P$  の情報を更新する。つまり、ノード  $Q$  へのリクエストがハートビートとなっている。またノード  $Q$  へのリクエストの内容をノード  $P$  のもつ情報のタイムスタンプだけ (ダイジェストと呼ぶ) を送信することでノード  $Q$  からノード  $P$  へのデータ量を削減することができる。

- Pull&Push 型 (図 4.1:右)

Pull&Push 型は Pull 型と同様である。違いは、ノード  $Q$  からノード  $P$  へ更新情報を送信する際にノード  $Q$  のダイジェストも添付し




図 4.1: gossip プロトコル

ておくことである。その後ノード  $P$  からノード  $Q$  へ情報が更新される。

このようにハートビートと情報伝播を同時に行うことで伝搬時間の遅延の抑制、通信量の削減が可能である。

### 4.3 Scuttlebutt

クラウドストレージにおける故障検知はメインタスクではない。そこで、故障検知における CPU サイクル、ネットワーク帯域幅の消費はできるかぎり抑えなければならない。そのようなリソース消費を抑えた情報共有プロトコルである Scuttlebutt [5] について詳しく説明する。Scuttlebutt は Pull&Push 型 gossip プロトコルを応用したプロトコルである。

これまではノード  $A$  の故障情報というように、ノード  $A$  をキーにして故障しているかどうかの値を定めていた。しかし Scuttlebutt ではさらに一般的に議論していて、 $A$  というキーの下に、キーバリューのペアを複数もつことを想定している。各メンバーそれぞれがもつ情報を、システム全体として整合性を保ちつつ、融合していく方法について言及している。Scuttlebutt ではメンバー同士でやりとりする情報に制約をかけることで、システム全体の整合性を保ちつつ、CPU やメモリーなどのリソースの消費を抑えることができる。

Scuttlebutt とは、分散システムで結果整合性モデルで各メンバーが保持する情報を融合をするためのプロトコルの一つである。結果整合性とは、システムに一時的に整合性が取れていない状態が生まれても、ある期間の後には整合性がとれた状態になることが保証されていることである。例えば、DNS システムなどである。[1] Pull&Push 型アプローチを採用している。特に、使用できるネットワーク帯域幅、CPU サイクルが限定されているときを想定している。つまり、使用するネットワーク帯域幅を抑えるためにある MTU (Message Transfer Unit) が決められていると仮

定して、MTU のサイズ内で情報を融合できるように工夫し送信を行うのである。具体的には、更新する情報に優先順位をつけて必要な情報だけを相手に伝搬させることで、システムの整合性を保ちつつ、ネットワーク帯域幅の消費を抑えた情報融合を可能にする。

通信手順について説明する。メンバーの集合を  $P = \{p, q, \dots\}$  とし、各メンバーがマッピング  $\sigma \in S = K \rightarrow (V \times N)$  にモデル化された状態を保持している。ここで、 $K$  はキーのセット、 $V$  は値のセット、 $N$  は有限の順序付けられたバージョン番号の集合を表している。 $\sigma(k) = (v, n)$  は、キー  $k$  が値  $v$  と、バージョン番号  $v$  にマップすることを意味している。また最近のマッピングほどバージョン番号が大きい。メンバーの状態は変更があり、またすべてのノードで複製化され保持している状態を考える。そこでノード  $p$  が保持する各メンバーのマッピングを  $u_p: P \rightarrow S$  とモデル化する。

メンバーの状態の更新を考える。メンバー  $p$  は、 $u_p(p)$  に対する更新のみが行えて、 $u_q(p), p \neq q$  に対しては gossip を通じて間接的にしか更新することができない。Scuttlebutt においての  $u_p(p)$  に対する更新では、一度に一つのキーに対する更新のみが可能であり、更新したキーに対するバージョンは、 $p$  が保持するマッピングの中のバージョン ( $\max(\sigma_p)$ ) よりも大きな値に更新する規則がある。メンバー  $p$  とメンバー  $q$  における更新では、 $u_p(r)$  に対する更新つまり融合では、バージョンが大きいキーの値で更新される。 $\sigma_1(k) = (v_1, n_1)$  と  $\sigma_2(k) = (v_2, n_2)$  が融合し、 $\sigma$  が生成されるとする。 $n_1 > n_2$  であれば  $\sigma = (v_1, n_1)$ 、そうでなければ  $\sigma = (v_2, n_2)$  となる。ここで、ある特定のメンバー  $p$  が持つキー  $k$ 、値  $v$ 、バージョン  $n$  のタプルを *delta* を名付ける。

Scuttlebutt では以下のように通信が行われる。

1. メンバー  $p$  が保持する各メンバーについて mapping の中で一番新しいバージョンだけ ( $\{(r, \max(u_p(r)) | r \in P)\}$ ) をメンバー  $q$  に送信する。
2. 同様に、メンバー  $q$  が保持する各メンバーについて mapping の中で一番新しいバージョンだけ ( $\{(r, \max(u_q(r)) | r \in Q)\}$ ) をメンバー  $p$  に送信する。
3. 上のようなダイジェストを受信したメンバー  $q$  は、下で定義している  $\Delta_{scuttle}^{p \rightarrow q}$  をメンバー  $q$  に送信する。
4. 3. と同様に、メンバー  $p$  から  $\Delta_{scuttle}^{q \rightarrow p}$  をメンバー  $p$  に送信する。

$$\Delta_{scuttle}^{p \rightarrow q} = \{(r, k, v, n) | u_p(r)(k) = (v, n) \wedge n > \max(u_q(r))\}$$

すなわち、 $\Delta_{scuttle}^{p \rightarrow q} = \{(r, k, v, n) | u_p(r)(k) = (v, n) \text{ とは、あるメンバー } r \text{ についてメンバー } q \text{ がまだ更新していないキーの } delta \text{ ということである。}$

このようにはじめに、各メンバーに対する最大のバージョン番号をダイジェストとして通信することで、無駄な通信を省略することができる。さらに MTU が存在するときには、手順 3. 手順 4. ですべての更新情報を送信することはできない。そこでバージョンが小さい *deltas* に優先順位をつけて更新の選択を決定することになる。この選択により、システムの整合性を保ちつつ効率的な通信が可能になる。

## 第5章 Cassandraについて

### 5.1 Cassandraの概要

Apache Cassandra は、Facebook 社によって開発され、Apache プロジェクト [6] としてオープンソース化されたクラウドストレージである。複数のデータセンター上に分散して配置された数百ノードで構成されることを想定しており、高い可用性と単一故障点を持たない非集中な分散モデルが大きな特徴である。このような大規模な環境では平均故障間隔は短く、故障検知が重要である。

#### 5.1.1 メンバーシップ管理

Cassandra を構成する各ノードは、リング上 ID 空間に配置される。各ノードは、クラスタに参加しているすべてのメンバーを gossip により把握する。また新規ノードを追加する時は、最初にコンタクトを取るノードの (これを seed と呼ぶ) 情報を予め設定しておくことで、スムーズにシステムに参加できる。メンバーシップ管理は、上述した gossip プロトコルの応用である Scuttlebutt をベースに行っている。ここでは、Scuttlebutt を使用したノード同士の情報交換を gossip 通信とする。具体的には、以下の手順に沿って毎秒情報交換が行われている。

1. STEP1: ランダムで生存ノードを一つ選択して gossip 通信を行う。
2. STEP2: 生存ノード数と故障が疑われるノード数に応じたある確率で、故障が疑われるノードをランダム一つ選択し gossip 通信を行う。
3. STEP3: STEP1 で seed 以外に gossip 通信を行ったとき、あるいは seed のノード数より生存ノードが少ないときのみを対象とする。この時、生存ノード、seed、故障が疑われるノードの数に応じたある確率で、seed の中からランダムで一つを選択して gossip 通信を行う。

スタンドアロン形式で Cassandra ノードを立ち上げる場合を除き、この方式により毎秒 1~3 回の gossip 通信を行っている。

## 第6章 Cassandraの軽量化と測定手法

### 6.1 Cassandraの軽量化

通信量のスケーラビリティを評価するためには、Cassandra ノードを多数起動する必要がある。しかしながら、物理リソースの都合上 10 台のマシンのみが利用可能であった。そこで、マシン 1 台あたりに多数の Cassandra ノードを起動することが必要になった。

そもそもデフォルトでは、Cassandra は 1 マシンで複数ノードが起動できるような仕組みになっていない。そこで、複数ノード起動ができるように通信のポート番号の変更するなどした。さらに一度に多数ノードが起動できるようなスクリプトを作成した。

しかしながら、1 ノードの Cassandra を起動するために、デフォルトの設定でデータを全く保持していない状態で、スレッド数が 130、メモリー使用量が 120 Mbyte 程度とリソースを多く消費する。(以後、 $G = 2^{30}$ 、 $M = 2^{20}$ 、 $K = 2^{10}$  とする) またクラスタを構成した際には、さらに 1 ノードあたりのリソース消費量が増える。多数ノードの Cassandra を起動するには、1 ノードを起動するためのリソースの消費を抑える必要があった。そこで、Cassandra データ保持部分のプログラムの改変と、設定パラメータのチューニングを行った。

#### 6.1.1 プログラムの改変

Cassandra は、データを保持していない状態であってもシステム管理のためのテーブルを保持する必要がある、メモリー使用量がかさむ。メモリー使用量を減らすためにプログラムに改変を加える。gossip の通信量を測定する実験では、データを読み書きするオペレーションはない。そこで、実際のデータを保存するのではなくデータサイズだけを保管するように変更しメモリー使用量を削減した。



### 6.1.2 設定ファイルのパラメータ調整

**JVM 最大ヒープサイズの制限を変更** Cassandra は Java 仮想マシン (JVM) 上で動作する。多数ノードを起動するために、JVM 最大ヒープサイズの制限をデフォルトの 1 Gbyte から 160 Mbyte に変更した。

**設定ファイルのパラメータ調整** 設定ファイルにて、同時に読み込みを許す最大値、同時書き込みを許す最大値を制限することでスレッド数を減らした。

また、これらのパラメータの調整も、gossip の通信量を測定する実験では、直接関わらないパラメータである。これらの調整により、1 マシンあたり Cassandra を最大 65 ノードまで起動することができた。

## 6.2 測定手法

非集中型クラウドストレージのスケーラビリティを評価するために以下の実験を行った。

- 実験 1:gossip の通信量の測定
- 実験 2:データ読み書きの通信量の測定

### 6.2.1 実験 1:gossip の通信量の測定

実験 1 では gossip の通信量の測定を行った。実験では、マスターとなるマシンを 1 台とワーカーとなるマシンを 10 台を用意した。ワーカーマシンを Node1, Node2, ...Node20 と名付ける。マスターの役割は、通信量計測の開始・終了、Cassandra ノードの起動、計測した記録の解析をワーカーに指示し、最終的な通信量の推定を行うことである。一方、ワーカーの役割は、通信量の計測、Cassandra ノードを起動、通信量の解析である。また、1 台あたり複数の Cassandra ノードを立ち上げる必要がある。Cassandra ノードの立ち上げ方は、30 秒ごとに、1 台あたり 10 ノードの Cassandra を一度に起動し、これを目指す台数に達成するまで続ける。最初の Cassandra ノードを起動した瞬間から各マシンで 10 分間の通信量を計測した。

計測後に各マシンで通信量を解析し、マスターとなるマシンに解析結果を送信する。マスターは、送られて通信量から合計値を出し、Cassandra で発生する通信量の推定を行う。

マスター、ワーカーで実行するプログラムは、シェルスクリプトでプログラムを書き、各ワーカーへの指示は、GXP [8] を使用して制御した。

GXPは、同じコマンドを多数のホストで並列に実行するための制御ツールである。また、パケット情報の解析にはJava, R, シェルスクリプトを用いた。

### 6.2.2 実験2:データ読み書きの通信量の測定

実験2ではアプリケーションを用いてデータの読み書きを行ったときの通信量の測定を行った。実験シナリオは、マスターとなるマシンを1台とワーカーとなるマシンを5台を用意し、実験1と同様の手順でCassandraの起動、通信量の測定を行った。

データを読み書きするアプリケーションとして、Yahoo! Cloud Serving Benchmark (YCSB) を使用した。YCSB [7] は Yahoo! Research が開発したクラウドストレージ用のベンチマークである。

### 6.2.3 計測方法について

実験1、実験2の計測にあたっていくつか工夫した共通の点を紹介する。

**ユーザー、プロセスのシステムリソース制約を外す** 通常のオペレーションシステムでは、1ユーザ、1プロセスに共有のシステムリソースを占有されないように管理がされている。具体的には、1ユーザが同時に実行出来るプロセス数、ファイル・ディスクリプタの数であったり、ユーザーが実行するプロセスにおいては、仮想メモリーの使用量、物理メモリーの使用量などについて制限がされる。

我々の実験環境では、数ノードでクラスタを構成するだけで1ノードあたりスレッド数が130程度必要であり、クラスタを構成するノード数が増加するとさらに増加する。Linuxのデフォルトの設定では、1ユーザが同時に実行出来るプロセス数は1024であるので、Cassandraを7ノードまでしか起動できなかった。(図6.1)

そこで、Linuxのユーザーリソースを決める設定ファイルを編集し、1ユーザーのリソース制限、1プロセスのリソース制限を緩和した。(図6.2) その結果、多数ノードの起動が可能になった。

**NFSを利用した書き込みをできるだけ控える** 概して一度に多数ノードを起動するときは、実行ファイルを共通にして起動することが多い。すなわち、NFS上に共通の実行スクリプトを保存し、実行時に読み込むことが多い。しかしながら、一度に非常に多数のNFSを通じた読み込みが発生すると、上手くアクセス出来ないことがある。そこで、各マシンのロー

```
[okudera@lime01 ~]$ ulimit -a
core file size          (blocks, -c) 0
data seg size           (kbytes, -d) unlimited
scheduling priority     (-e) 0
file size               (blocks, -f) unlimited
pending signals         (-i) 257704
max locked memory       (kbytes, -l) 64
max memory size         (kbytes, -m) unlimited
open files              (-n) 1024
pipe size               (512 bytes, -p) 8
POSIX message queues    (bytes, -q) 819200
real-time priority      (-r) 0
stack size              (kbytes, -s) 8192
cpu time                (seconds, -t) unlimited
max user processes      (-u) 1024
virtual memory          (kbytes, -v) unlimited
file locks              (-x) unlimited
```

図 6.1: リソース制限変更前

カル上に実行ファイルを保管し起動時にそのファイルを読み込むようにした。

**IP エイリアシングを利用し、プライベートネットワークを構築** Cassandra のメンバー管理では、IP アドレスでメンバーを認識する。今回の実験のように 1 マシンあたり複数ノードの Cassandra を立ち上げようとする、不都合が生じる。つまり、同じマシン上で立ち上げた Cassandra ノードは、他のマシンからは同一のノードと認識されてしまうのである。

そこで、IP エイリアシングを使用して仮想アドレスを作成し、Cassandra ノードに割り振ることにした。その結果、同じマシン上に立ち上がった Cassandra マシン同士の区別が可能になり、不整合が起きなくなった。

さらに、通信量の測定の際にはノイズを防がないといけない。ノイズとは、Cassandra ノード以外から要求されるリクエストのことである。具体的には、ARP や ssh などのパケットのことである。これらのパケットを誤って計測してしまうことを避けるために、IP エイリアシングを行うと同時に、プライベートネットワークを構築した。よって、このネットワークに参加しているのは Cassandra ノードだけである。つまり、プライベートネットワーク内で飛び交うパケットのみを取得することが簡単にできる。

具体的には、10.20.0.0/16 のネットワークを構築した。さらに Cassandra ノードが物理的にどのマシン上で起動しているかを判別しているために、

```
[okudera@lime20 ~]$ ulimit -a
core file size          (blocks, -c) 0
data seg size           (kbytes, -d) unlimited
scheduling priority     (-e) 0
file size               (blocks, -f) unlimited
pending signals         (-i) 257704
max locked memory       (kbytes, -l) unlimited
max memory size         (kbytes, -m) unlimited
open files              (-n) 1024
pipe size               (512 bytes, -p) 8
POSIX message queues    (bytes, -q) 819200
real-time priority      (-r) 0
stack size              (kbytes, -s) 8192
cpu time                (seconds, -t) unlimited
max user processes      (-u) unlimited
virtual memory          (kbytes, -v) unlimited
file locks              (-x) unlimited
```

図 6.2: リソース制限変更後

実マシン (Node11, Node12, ..., Node20) 上のノード番号  $n$  を使用し、Node[ $n$ ] 上で起動するマシンに仮想的に 10.20. $n$ .0/24 なるサブネットを設けた。例えば、実マシン Node19 で起動する Cassandra ノードに割り当てられる仮想アドレスは、10.20.19. $x$  ( $1 < x < 254$ ) となる。図 6.3 がプライベートネットワークを構築後に `ifconfig` コマンドを実行したときの実行結果で、このネットワーク内で Cassandra クラスタが構成されている様子が図 6.4 である。

**tcpdump の使用** 通信量の測定は `tcpdump` を使用した。上述したような Cassandra ノードのプライベートネットワーク上で飛び交う、パケットを記録した。具体的には TCP パケットのパケットサイズを記録した。また、`tcpdump` に以下のオプションをつけて実行した。取得するパケットは二つの条件でフィルターをかけた。

- `src net 10.20.0.0/16`

このフィルターにより、指定したデバイスを経由したパケットのうち、送信元が 10.20.0.0/16 のネットワークであるパケットのみが取得する。つまり、これで、このネットワーク以外のパケットを取得しないことになる。この条件で、余計な ARP クエリなどを弾ける。

- `dst net 10.20.(マシン番号).0/24`

このフィルターにより、指定したデバイスを経由したパケットのう

```
eth0:1  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.1  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:2  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.2  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:3  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.3  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:4  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.4  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:5  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.5  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:6  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.6  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:7  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.7  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:8  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.8  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:9  Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.9  Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800

eth0:10 Link encap:Ethernet  HWaddr 84:2B:2B:64:86:88
        inet addr:10.20.20.10 Bcast:10.20.255.255  Mask:255.255.0.0
        UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
        Interrupt:36  Memory:da000000-da012800
```

図 6.3: ifconfig の実行結果

```
[okudera@lime19 bin]$ ./nodetool -h 10.20.20.1 -p 8081 ring
```

Address	Status	Load	Range	Ring
			169180376881269628403480787642570762075	
10.20.18.6	Up	495 bytes	11113760188773492771394413125304693187	<--
10.20.17.2	Up	495 bytes	14815710709846775516269280299431883097	^
10.20.17.1	Up	495 bytes	16590253349306961039241751110255739027	v
10.20.17.6	Up	495 bytes	22294807489085145125230590133499117598	^
10.20.20.4	Up	495 bytes	26073771464406995879200775520799405043	v
10.20.20.1	Up	495 bytes	26861172263200552172822123627443432845	^
10.20.16.4	Up	495 bytes	35421431719939672775512982915093097219	v
10.20.20.2	Up	495 bytes	45034240559505758984599935570830731937	^
10.20.16.6	Up	495 bytes	45224474326790813669567715772665182694	v
10.20.16.2	Up	495 bytes	57332423708959802652608770505193313495	^
10.20.18.5	Up	495 bytes	57608296435673572359375621632391068717	v
10.20.20.3	Up	495 bytes	58048888845713484646814654384602755659	^
10.20.18.4	Up	495 bytes	60502640439766815324455008831724001878	v
10.20.19.3	Up	495 bytes	65401906357653153493682023469701445831	^
10.20.19.4	Up	495 bytes	68916625974952483239167138707287329525	v
10.20.16.1	Up	495 bytes	79525459341385738805222019615652455875	^
10.20.16.5	Up	495 bytes	81648594761384172431443984133741312411	v
10.20.17.3	Up	495 bytes	90534095758705485133809224359417327758	^
10.20.19.6	Up	495 bytes	94276063823310114573768240102995511934	v
10.20.18.3	Up	495 bytes	96428013003280111015704865330431319687	^
10.20.20.5	Up	495 bytes	115536254213812968781603144480528659407	v
10.20.17.4	Up	495 bytes	116057395662412152539005385433006110363	^
10.20.18.1	Up	495 bytes	118331362875818037407837981329128097759	v
10.20.20.6	Up	495 bytes	120177157666681819044802242041320586570	^
10.20.17.5	Up	495 bytes	140038670664330997718516444687165924160	v
10.20.19.1	Up	495 bytes	140746655400214165971187825325530326086	^
10.20.19.2	Up	495 bytes	149494985536248049937854533104206081972	v
10.20.18.2	Up	495 bytes	151768813669109044693976960569868080469	^
10.20.16.3	Up	495 bytes	164425287327808289139031510855023468502	v
10.20.19.5	Up	495 bytes	169180376881269628403480787642570762075	-->

図 6.4: Cassandra クラスタを構成したときの様子

ち、受信元が 10.20.(マシン番号).0/16 のネットワークであるパケットのみが取得できる。つまり、tcpdump を実行するマシンで実行する Cassandra ノード宛のパケットだけを取得することができる。

この 2 つの条件により、他のマシンで起動している Cassandra ノードからこのマシンで起動している Cassandra ノードに送られてくるパケットだけを取得できるのである。図 6.5 が tcpdump を実行したときの実行結果の例である。

**同じマシン上で動作している Cassandra ノード同士の通信は取得できない** 一方、tcpdump で測定する方法では同じマシン上で動作している Cassandra ノード同士の通信は取得できないことに留意したい。

```
15:10:44.202766 IP (tos 0x0, ttl 64, id 42399, offset 0, flags [DF], p
roto TCP (6), length 60)
    10.20.17.6.34338 > 10.20.19.16.afs3-callback: Flags [S], cksum 0x5
1b4 (correct), seq 674710703, win 5840, options [mss 1460,sackOK,TS va
l 3081494832 ecr 0,nop,wscale 7], length 0
15:10:44.202800 IP (tos 0x0, ttl 64, id 43887, offset 0, flags [DF], p
roto TCP (6), length 60)
    10.20.17.4.58813 > 10.20.19.15.afs3-callback: Flags [S], cksum 0xe
d30 (correct), seq 661801567, win 5840, options [mss 1460,sackOK,TS va
l 3081494832 ecr 0,nop,wscale 7], length 0
15:10:44.202830 IP (tos 0x0, ttl 64, id 10585, offset 0, flags [DF], p
roto TCP (6), length 60)
    10.20.18.6.52625 > 10.20.19.17.afs3-callback: Flags [S], cksum 0x3
7b1 (correct), seq 2554030828, win 5840, options [mss 1460,sackOK,TS v
al 2423800757 ecr 0,nop,wscale 7], length 0
15:10:44.202992 IP (tos 0x0, ttl 64, id 0, offset 0, flags [DF], proto
TCP (6), length 40)
    10.20.17.20.afs3-callback > 10.20.19.5.60264: Flags [R.], cksum 0x
1059 (correct), seq 0, ack 666515643, win 0, length 0
15:10:44.203024 IP (tos 0x0, ttl 64, id 27190, offset 0, flags [DF], p
roto TCP (6), length 60)
    10.20.17.6.57470 > 10.20.19.14.afs3-callback: Flags [S], cksum 0xb
190 (correct), seq 665422598, win 5840, options [mss 1460,sackOK,TS va
l 3081494832 ecr 0,nop,wscale 7], length 0
15:10:44.203937 IP (tos 0x0, ttl 64, id 4156, offset 0, flags [DF], pr
oto TCP (6), length 60)
    10.20.17.4.43489 > 10.20.19.18.afs3-callback: Flags [S], cksum 0x8
1b7 (correct), seq 672526605, win 5840, options [mss 1460,sackOK,TS va
l 3081494833 ecr 0,nop,wscale 7], length 0
15:10:44.203988 IP (tos 0x0, ttl 64, id 9900, offset 0, flags [DF], pr
oto TCP (6), length 60)
    10.20.17.6.46065 > 10.20.19.8.afs3-callback: Flags [S], cksum 0xa0
f4 (correct), seq 675334045, win 5840, options [mss 1460,sackOK,TS val
3081494833 ecr 0,nop,wscale 7], length 0
```

図 6.5: tcpdump の実行結果

## 6.2.4 通信量の推定

### 6.2.4.1 実験 1:gossip の通信量の推定

tcpdump を使用した上のような計測方法では、同じマシン上での Cas-sandra ノード同士の通信を計測することはできない。そこで我々は以下の仮定をもとに、計測した通信量から Cassandra ノードで発生する gossip の通信量を推測することにした。

- 仮定: 同じマシン上で動作する Cassandra ノードとの通信量の平均と異なるマシン上で動作する Cassandra ノードとの通信量の平均は等しい

各 Cassandra ノードから見れば、同じマシン上で動作する Cassandra ノードも異なるマシン上で動作する Cassandra ノードも区別はないので、この過程は妥当である。この仮定から、測定できないマシン内部での通信量をマシンをまたいだ通信を計測することで、推定が可能になる。

gossip の通信量の推定について説明する。 $m$  台の各マシンで cassandra を  $n'$  ノード (ただし、 $n' > 2$  とする) 起動する。つまり、システム全体で合計  $n \times m$  ノードの Cassandra が起動されている。各マシンで `tcpdump` を使用して計測した得られた通信量の合計を  $T_t$  とし、推定する Cassandra ノードで発生する通信量  $T$  とする。 $T_t$  は、 $(n-1) \times m$  ノードの Cassandra から取得した  $n \times m$  ノードの合計通信量である。上の仮定を用いると、 $((n \times m) - 1)$  ノードから取得する通信量  $T$  は、

$$T = T_t \times [(n' \times m) - 1] / ((n' - 1) \times m) \quad (6.1)$$

と Cassandra ノードで発生する gossip の通信量を推測することができた。

具体的に  $n = 4, m = 2$  の時を例に取り上げる。つまり、マシン 2 台上でそれぞれ Cassandra を 2 ノードを起動する状況を考える。(図 7.1) また、各マシンは受信する通信量しか計測していないことに注意する。

このとき、測定可能な通信量から、測定不可能な通信量を見積ればよい。マシン A が測定しているのは、ノード 3, 4 からノード 1 への通信とノード 3, 4 からノード 2 への通信である。同様にマシン B が測定しているのは、ノード 1, 2 からノード 3 への通信とノード 1, 2 からノード 4 への通信である。それぞれ、 $T^A, T^B$  とおく。また、測定出来ていないのは、ノード 1 からノード 2、ノード 2 からノード 1、ノード 4 からノード 3、ノード 3 からノード 4 の通信である。これをまとめて  $T^C$  とおく。 $T^A, T^B, T^C$  はともに 4 つの Cassandra ノード同士の通信の合計である。

上の仮定を利用すると、 $T^C$  は、マシン A、B で測定した通信から見積もることができる。つまり、

$$T^C = (T^A + T^B) / 2 \quad (6.2)$$

よって Cassandra ノード間で発生する通信は、

$$T = (T^A + T^B) / 2 + T^A + T^B \quad (6.3)$$

$$= (T^A + T^B) \times 3 / 2 \quad (6.4)$$

$$= (T^A + T^B) \times (2 \times 2 - 1) / [(2 - 1) \times 2] \quad (6.5)$$

と推測できる。これは式 6.1 にしたがう。






図 6.6: gossip 通信量の推定

#### 6.2.4.2 実験 2: データ読み書きの通信量の推定

次にデータ読み書きの通信量の推定方法について考える。まず、Cassandra のデータ読み書き時の通信手順を説明する。クライアントと直接データの受け渡しを行う Cassandra ノードを proxy ノードと呼ぶ。書き込み時には、proxy ノードから担当ノードへデータが転送され、担当ノードは proxy ノードにデータ書き込みが成功したことを知らせる、いわゆる Ack を返す。読込時には、proxy ノードが担当ノードに読み込みリクエストを転送し、受信した担当ノードがデータを転送する。

つまり、データ読み書きがある場合に発生する通信の種類は、データの転送、データ書き込み成功の Ack, 読み込みのリクエスト、そして gossip による通信の 4 種類である。実験 2 で Gossip の通信量は測定しているので、計測した通信量から差し引くことで推定ができる。また gossip の通信は、メンバー構成が安定しているときにはデータの読み書きによらず一定であることに留意する。

まず、YCSB クライアントの動作について説明する。YCSB のクライアントは、Cassandra1 ノードだけと接続してデータの読み書きを行う。データの読み書きのワークロードは選択できる。今回の実験では、読み書きが半々の比率であるワークロードを選択した。

データ通信量  $T$  を推定する。proxy ノードが動作するマシンで取得した通信量を  $T^A$ 、proxy ノード以外のノードが動作するマシンで取得した通信量の合計を  $T^B$  として、それぞれ gossip の通信量を  $T_{gossip}^A, T_{gossip}^B$  とおく。このときデータ通信量  $T$  は、

$$T = [(T^A - T_{gossip}^A) + (T^B - T_{gossip}^B)] \times [(n-1)/n] \times [m/(m-1)] \quad (6.6)$$

で得られる。具体的に  $n = 4, m = 2$  の場合について説明していく。書き込み時、読み込み時に分けて推定を行う。実際は、読み書きのリクエストが混ざっているが、どちらも同じ式で推定できるため、式 6.6 で十分である。




図 6.7: データ通信量の推定 ～gossip の通信を含む～

**書き込み時** 書き込み時に発生する通信は図 6.7 にあるように、gossip の通信、データ書き込みの通信、ack の通信の 3 つである。proxy ノードが動作するマシンで取得した ack の通信量を  $T_{ack}^A$ 、proxy ノードがないマシンで取得したデータ書き込みの通信量の合計を  $T_{data}^B$  とおく。すなわち

$$T^A = T_{gossip}^A + T_{ack}^A \quad (6.7)$$

$$T^B = T_{gossip}^B + T_{data}^B \quad (6.8)$$

が成立している。各マシンで取得した通信量から gossip の通信量を差し引く。これはデータの読み書きに応じて gossip 通信量が変化しないことか




図 6.8: データ通信量の推定 ～gossip の通信を含まず～

ら問題ない。また gossip の通信量は、データの読み書きをする前後で計測可能である。gossip による通信を除いた通信は、proxy ノードから proxy ノード以外へデータを転送する通信と、proxy ノード以外のノードから proxy への ack の通信である。これを表したのが図 6.8 である。このとき、Cassandra ノード全体で発生する ack の通信量を  $T_{ack}$  とおけば、

$$T_{ack} = T_{ack}^A \times 3/2 \quad (6.9)$$

である。Cassandra ノード全体で発生するデータ書き込みの通信量を  $T_{data}$  とおくと、

$$T_{data} = T_{data}^B \times 3/2 \quad (6.10)$$

である。一方、

$$T = T_{ack} + T_{data} \quad (6.11)$$

であるので、

$$T = (T_{ack}^A + T_{data}^B) \times 3/2 \quad (6.12)$$

$$= [(T^A - T_{gossip}^A) + (T^B - T_{gossip}^B)] \times 3/2 \quad (6.13)$$

である。これは、式 6.6 にしたがう。

**読み込み時** 読み込み時も同様である。読み込み時の通信の流れを図 6.9 に表した。読み込み時に発生する通信は、gossip の通信、データ読み込みの通信、データのリクエストの通信の 3 つである。gossip の通信を除いた通信の流れが図 6.10 である。書き込み時におけるデータによる通信をデータのリクエストに、ack をデータによる通信に置き変えたのが読み書き時の通信の流れになる。書き込み時と同様に、proxy ノードが動作するマシンで取得したデータ通信量を  $T_{data}^A$ 、proxy ノードがないマシンで取得したリクエストの通信量の合計を  $T_{request}^B$  とおく。このとき、

Cassandra ノード全体で発生するデータの通信量を  $T_{data}$  とおけば、

$$T_{data} = T_{data}^A \times 3/2 \quad (6.14)$$

Cassandra ノード全体で発生するリクエストの通信量を  $T_{request}$  とおけば、

$$T_{request} = T_{request}^B \times 3/2 \quad (6.15)$$

一方、

$$T = T_{data} + T_{request} \quad (6.16)$$

であるので、

$$T = (T_{data}^A + T_{request}^B) \times 3/2 \quad (6.17)$$

$$= [(T^A - T_{gossip}^A) + (T^B - T_{gossip}^B)] \times 3/2 \quad (6.18)$$

である。これは、式 6.6 にしたがう。

$n = 4$ 、 $m = 2$  の場合に、読み書き両方においてデータの通信量は、式 6.6 で推測できることが確認できた。

## 6.3 通信量測定のためのプログラムの作成

図 6.11 のような自動で通信量の測定を行い、その後解析を行うプログラムを作成した。

### 6.3.1 実験環境

以下に実験環境を示す。

- Cassandra 0.6.6
- OS Linux 2.6.35.10 74.fc14.x86\_64

- CPU: 2.40 GHz Xeon E5620 × 2
- Java 仮想マシン: Java SE 6 Update 21
- メモリー: 32GB RAM
- ネットワーク: 1000BASE-T




図 6.9: データ通信量の推定 ～gossip の通信を含む～




図 6.10: データ通信量の推定 ～gossip の通信を含まず～

```

#!/bin/sh
#===== 0.実験の初期化 =====
#設定ファイル(実験パラメータ)の読み込み。
#Cassandra実行ファイルのホームディレクトリが記述されている。
. $E_PARA_INCLUDE
#現在時刻を取得、これがそれぞれの実験を識別するものになる。
date=`date +%Y%m%d%H%M%S`

#データ保存フォルダの作成
final_result_data_directory="{cassandra_final_result_home}/nodes${node_number}"
if [ ! -e $final_result_data_directory ];then
    mkdir $final_result_data_directory
fi
mkdir $final_result_data_directory/$date

#メタ情報(実験パラメータ)の保存
echo "nodes=${node_number},\
span=${measuring_span}\
worker_ids=${worker_node_ids[@]}"
">$final_result_data_directory/$date/meta-info

cat /home/okudera/work/cassandra-lite/measure-tool/dynamic_seeds_conf \
>> $final_result_data_directory/$date/meta-info
#leave worker id in meta-info
echo ${worker_node_ids[@]} \
> $final_result_data_directory/$date/worker_node_ids

#=== 1.GXPCジョブスケジューラを使用して各ノードでジョブを実行。初期設定 ===
admin_node_name=`hostname`
gxpc use ssh $admin_node_name $cluster_name
for i in ${worker_node_ids[@]}
do
    gxpc explore $cluster_name[${i}]
done

#===== 2.計測を開始する =====
#各ノードでmeasureTCPPacketスクリプトを実行する
#measureTCPPacketスクリプトでは、以下が行われる。
#1.計測の開始
#2.Cassandraの起動,
#3.計測時間経過後にCassandraの停止
#4.計測の終了
gxpc e ${measure_tool_directory}/measureTCPPacket $date $measuring_span \
$each_node_number $final_result_data_directory/$date

#すべてのノードで計測が終了した後次のステップに進む
#=== 3.計測した通信量情報から必要な情報だけを取得。各ノードで解析を行う ===
gxpc e ${measure_tool_directory}/analyzeTraffic \
$date $final_result_data_directory

#各ノードで解析したデータを集約する。
R --vanilla --slave --args $final_result_data_directory/$date \
< ${measure_tool_directory}/R/reduceData.R

#データを集約してからCassandraノード同士で発生した通信量を推定する。
R --vanilla --slave --args $final_result_data_directory/$date \
< ${measure_tool_directory}/R/calculateWholeThroughput.R
gxpc quit

```

図 6.11: 実行スクリプト

## 第7章 実験・評価

### 7.1 予備実験

本実験に入る前に以下の予備実験を行った。

#### 7.1.1 予備実験 (1) gossip の通信量推定の妥当性

この実験によって、Cassandra ノードで発生する gossip の通信量の推定が妥当であることを裏付ける。異なるマシン数で同数の Cassandra ノードを立ち上げて通信量の推定を行い比較する。予備実験では、120 ノードの Cassandra を TypeA、TypeB の 2 パターンで立ち上げ、10 分間の計測後に推定される通信量が一致することを確認する。推定される通信量を  $T$  とおく。

- TypeA  
一台あたり 12 ノードの Cassandra を立ち上げたマシン 10 台でのクラスタを構成
- typeB  
一台あたり 60 ノードの Cassandra ノードを立ち上げたマシン 2 台でのクラスタを構成

Type A の場合は、1 秒あたりの通信量を  $A(t)$  とおくと、式 6.6 から

$$T(t) = A(t) \times 119/110 \quad (7.1)$$

Type B の場合は、時間  $t$  の時の通信量を  $B(t)$  とおくと、同様に式 6.6 から

$$T(t) = B(t) \times 119/60 \quad (7.2)$$

となる。1 秒ごとに通信量を取得すると非常に変動が激しく、読み取りにくいデータになってしまう。そこで 10 秒ごとに通信量を集計し、1 秒あたりの平均を算出し、これを通信量の指標とした。以後の実験すべてにおいて、1 秒あたりの通信量とは、これを意味するものとする。各通信量の推定値をグラフに表したのが図 7.1 である。






図 7.1: マシン台数に応じた gossip の通信量の時間変化

横軸は時間軸で、縦軸は推定される通信量 (Mbit/s) である。(ただし、 $1M = 10^6$ ,  $1K = 10^3$  である。) 図 7.1 からマシン数が 2 台、10 台のときともに、200 秒以降は通信量が安定している。安定した後の推定される通信量はほぼ同じであることがわかる。よって、この推定が確からしいことが裏付けられた。

### 7.1.2 予備実験 (2) : データ読み書き通信量推定の妥当性

予備実験 (1) gossip 通信量推定の妥当性と同様に、Cassandra ノードで発生するデータ読み書きの通信量推定が妥当であることを裏付ける。そのために、異なるマシン数で同数の Cassandra ノードを立ち上げてデータ通信量の推定を行い比較する。ノード数は 120 と固定して、マシン数を 3, 4, 5 と変化させて通信量の推定を行った。1 秒あたりのクエリー数 (queries per




図 7.2: マシン台数別のデータ読み書きの通信量推定値

second, qps) を 5000 とした。その結果が図 7.2 である。横軸がマシンの台数で縦軸が YCSB のワークロード実行時のデータ通信量の平均 (Mbit/s) を表している。

構成するマシンが 3 台の時、通信量が 42.3 Mbit/s、マシンが 4 台の時 42.6 Mbit/s、マシンが 5 台の時 43.6 Mbit/s である。マシン台数が増えるにつれわずかに通信量も増加しているが、推定値がほぼ同じであることが確かめられる。よってこの推定がもっとももらしいことが裏付けられた。

### 7.1.3 予備実験 (3) : リクエスト量に応じたデータ読み書き通信量の増加

要求されるリクエストの量 (qps) を変化に応じた、Cassandra ノードで発生するデータ通信量 (Mbit/s) の変化を測定する。qps が増えると処理するリクエストの量が線形に増加するので、通信量も線形に増加していくことが予想される。ノード台数は 120 台と固定し、 $qps = 500, 1000, 2000, 3000, 4000$




図 7.3: リクエスト量に応じたデータ読み書き通信量の増加

と変化させてデータの読み書き通信量を測定した。図 7.3 が測定結果である。縦軸が qps で、横軸が YCSB のワークロード実行時のデータ総通信量である。

図中の直線は、プロットした点から 1 次関数でフィッティングしたものである。 $q$  を 1 秒あたりのクエリー発行数 (qps) として得られる関数は、

$$[\text{通信量 (bit/s)}] = 8727.9 \times q - 348939 \quad (7.3)$$

である。通信量は 1 秒あたりのクエリー数に応じて  $O(n)$  で増加していくことが確認できる。予想通りの結果が得られた。

## 7.2 本実験

### 7.2.1 実験 1:gossip の通信量

スケーラビリティ評価を行う。まず、gossip 通信量がノード台数に応じてどのように変化していくかを測定した。図 7.4 は、10 秒あたりの Cassandra

ノード間の平均 gossip 通信量の時間変化をノード数別に表したグラフである。(ただし、 $1M = 10^6$ ,  $1K = 10^3$  である。) ノード数によらず、100 秒以降は通信量が安定していることがわかる。図 7.5 は、ノード数と通信量が安定している時の (ここでは、実験開始から 200~300 秒後とした) 1 秒あたりの通信量の平均をプロットしたものである。

### 7.2.2 実験 2: データ読み書き通信量の測定

次に、データ通信量がノード数に応じてどのように変化していくかを測定した。*qps* (*queries/s*) は 1000 で一定であり、更新時のデータサイズは 1kbyte で固定してある。図 7.6 は、YCSB のワークロードを実行したときにデータ読み書きで発生した通信量 (Mbit/s) の平均をノード台数別に表したグラフである。ただし gossip の通信量は差し引いてある。




図 7.4: ノード数別の gossip 通信量の時間変化




図 7.5: ノード数に応じた gossip 通信量の増加




図 7.6: qps 一定時のノード数に応じたデータ読み書き通信量の変化

## 7.3 評価

### 7.3.1 gossip の通信量の見積もり

図中の曲線は、プロットした点から2次関数でフィッティングしたものである。 $n$  をノード数として得られた関数は、

$$[\text{通信量 (bit)}] = 224.6 \times n^2 + 4314.8 \times n \quad (7.4)$$

である。よって、gossip の通信量は  $O(n^2)$  で増加することがわかった。この関数から、ノード台数をパラメータとして Cassandra の gossip プロトコルで発生する全体の通信量を推測することができる。例えば、 $n = 1000$  のとき、 $[\text{通信量}] = 229\text{Mbps}$  となる。このように、関数を使って gossip による通信量が見積もることができる。

### 7.3.2 1 ノードあたりの通信量

同様に、1 ノードあたりの通信量を見積もることも可能である。ここでは受信する通信量のみを考えるが、受信する通信量と送信する通信量は等しい。総通信量を Cassandra ノード台数  $n$  で割った値が、1 ノードあたりの通信量となる。つまり、1 ノードあたりの通信量を  $T'$  として

$$T' = (224.6 \times n^2 + 4314.8 \times n) / n \quad (7.5)$$

$$= 224.6 \times n + 4314.8 \quad (7.6)$$

と  $O(n)$  で増加することがわかる。

### 7.3.3 複数のデータセンターをまたぐクラスタにおける gossip プロトコルの問題点

ケースとして2つのデータセンターをまたいでクラスタを構成することを考える。(図7.7) このクラスタで発生する通信量を見積もる。

このようにデータセンターを複数またいでクラスタを構成することは特別なことではない。データの複製を別のデータセンターに保持しておくことで、データセンター全体で故障が起きた場合でもデータの損失が避けられる。このように最近のクラウドストレージではデータセンターの故障にも耐性があるシステムを実現しているのである。

データセンター間を結ぶリンクで発生する通信量を見積もる。簡単のために Cassandra のノード数を  $n$  とした時、各データセンター A、B にそれぞれ  $n/2$  ノードが起動しているとする。この時、データセンター間で






図 7.7: 二つのデータセンターをまたぐクラスタの構成

の通信量  $T^{AB}$  は、システム全体で発生する通信量を  $T$  とおくと、 $T/4$  である。一方、式 7.4 より  $T$  は  $O(n^2)$  で増加するから  $T^{AB}$  も  $O(n^2)$  で増加する。

このように、クラスタを構成する各ノードの通信量は  $O(n)$  で増加していく一方で、データセンター間を結ぶリンクの通信量は  $O(n^2)$  で増加していく。つまり、ノード数が増加したときにこのリンク部分の通信が圧迫される可能性がある。現状の gossip プロトコルには、このようなデータセンター間のリンク部分を考慮したアルゴリズムではないことがわかる。

データセンターをまたいでクラスタを構成することが主流の現在において、リンク部分の通信量を考慮して gossip プロコルを応用することが望まれる。例えば、あるノードの故障情報をデータセンターをまたいで伝達させたいとき、現状の gossip プロトコルでは同じ情報を冗長に伝達することが多い。データセンターをまたぐお内内容の通信を取りまとめることができれば、データセンター間のリンクで発生する通信を削減できるだろう。

### 7.3.3.1 gossip の通信量が $O(n^2)$ で増加していく理由

gossip の通信量が  $O(n^2)$  で増加していく理由について考察する。総通信量  $T(\text{bit/s})$  は、1 ノードあたりの通信量 ( $\text{bit/s}$ ) を  $T'$ 、ノード数を  $n$  と

して、

$$T = T' \times n \quad (7.7)$$

である。さらに1秒毎の gossip 通信が行われる回数を  $s$ 、1回の gossip 通信にかかる通信量  $t_{gossip}(bit)$  として、1ノードあたりの通信量  $T'(bit/s)$  は、

$$T' = s \times t_{gossip} \quad (7.8)$$

となる。メンバー構成が安定した時を考える。Cassandra のメンバー管理シッでは、メンバー構成が安定したときは、毎秒1~2回の gossip 通信が行われる。よって1秒毎の gossip 通信する回数  $s$  は、

$$s < 2 = O(1) \quad (7.9)$$

一方、1回あたりの gossip 通信の通信量  $t_{gossip}(bit)$  は Scuttlebutt のアルゴリズムから安定時にはノード数に依存するので、

$$t_{gossip} = O(n) \quad (7.10)$$

よって式7.7より、1ノードあたりの通信量  $T'(bit/s)$ 、総通信量  $T(bit/s)$  は、

$$T' = O(n) \quad (7.11)$$

$$T = O(n^2) \quad (7.12)$$

となることが証明できた。

### 7.3.3.2 qps 一定時にデータ読み書きの通信量は一定

$qps$  を一定にしたとき、構成する Cassandra のノード数  $n$  に応じて、通信量の増加は緩やかになり一定の値に近づいていくことが確認できる。(図7.6から) これは直感的に明らかである。ノード数が  $n$  の時、クライアントとやり取りを行う proxy ノードがデータの担当ノードである確率は  $1/n$  である。つまり、クライアントが要求するデータに対して、 $(n-1)/n$  の確率で通信が発生することになる。よって、 $n$  が大きくなるとその確率は1に収束するのでほぼ必ずリクエストに対して通信が発生する。ノード台数  $n$  が増加すると、通信量はある一定値に近づいていく。実際、図7.6も一定値に近づいていくことが見てとれる。

## 第8章 結論

### 8.1 まとめ

本研究では非集中なクラウドストレージでの主要なメンバーシップ管理である gossip プロトコルについてスケーラビリティを Cassandra を使用して実験・評価した。計測の結果、gossip プロトコルによるシステム全体の通信量はノード数を  $n$  としたとき、 $O(n^2)$  で増加することを確認した。定量的にクラウドストレージの gossip ベースのメンバーシップに要する通信量を計測することができた。この結果は、クラスタ設計時等で gossip の通信量の見積もり際に重要である。2つのデータセンターをまたぐリンクにおいては、 $O(n^2)$  で通信量が増加しスケーラビリティの制約になりかねない。このようなケースを考慮した gossip プロトコルの応用した提案が望まれる。

### 8.2 今後の課題

今後の課題について3つ記す。

一つ目は、gossip プロトコルを採用しているクラウドストレージにおけるスケーラビリティ評価を、別の切り口から検討していくことである。参照 [4] でもあるように、故障検知プロトコルの評価は、通信量という切り口のほかに CPU 占有率や故障の伝搬スピードなどが挙げられる。本研究では通信量の観点からスケーラビリティの評価を行ったが、これらの指標からもスケーラビリティの評価が行える。通信量と比べてどちらが先にスケールするためのボトルネックとなりうるか議論ができる。

二つ目は、gossip プロトコル以外の故障検知プロトコルの通信量を評価し、比較することである。本研究では、gossip プロトコルのスケーラビリティ評価を行った。しかしながら、gossip 以外にも故障検知メカニズムは提案されている。例えば、情報を更新するとすべてのメンバーに全対全で情報を伝搬していくプロトコルや、近傍にだけ更新を伝えるプロトコルなどがある。これらのスケーラビリティ評価をし、比較することで gossip や他のプロトコルの特性を評価できる。

三つ目は、データセンター間のリンクでの通信量を考慮した gossip プロトコルの提案である。データセンター間のリンクでは、 $O(n^2)$  で通信量が増加しスケーラビリティの制約になりかねない。そこで、このようなリンクでの通信量を抑えるプロトコルが必要である。

## 参考文献

- [1] 丸山不二夫, 首藤一幸: クラウドの技術, Vol. pp.6–13, ASCII.
- [2] Miguel Matos, Ant ˆnio Sousa and Jose Pereira and Rui Oliveira and Eric Deliot and Paul Murray: CLON: Overlay Networks and Gossip Protocols for Cloud Environments, *NOMS Workshops '08* (2008).
- [3] Avinash Lakshman and Prashant Malik: Cassandra -A Decentralized Structured Storage System, *LADIS '09* (2009).
- [4] Marcia Pasin and St'phane Fontaine and Sara Bouchenak: Failure Detection in Large Scale Systems: a Survey, *NOMS Workshops '08* (2008).
- [5] Robbert van Renesse and Dan Dumitriu and Valient Gough and Chris Thomas and Amazon.com Seattle: Efficient Reconciliation and Flow Control for Anti-Entropy, *LADIS '08* (2008).
- [6] <http://wiki.apache.org/cassandra/FrontPage>: Cassandra Wiki.
- [7] Brian F. Cooper, Adam Silberstein, Erwin Tam, Raghu Ramakrishnan and Russell Sears: Benchmarking Cloud Serving Systems with YCSB, *SoCC '10* (2010).
- [8] 関谷岳史, 田浦健次朗: An Extension to Grid-Shell GXP for Persisting Computation, **情報処理学会論文誌** (2000).
- [9] Giuseppe De C, iaLA, Deniz Hastoruna, Madan Jampani, Gunavardhan Kakulapati, Avinash Lakshman, Alex Pilchin, Swaminathan Sivasubramanian, Peter Voss hall and Werner Vogels: Dynamo: Amazon's Highly Available Key-value Store, *SOSP '07* (2007).
- [10] Mayur Deshpande, Bo Xing, Iosif Lazardis, Bijit Hore, Nalini Venkatasubramanian and Sharad Mehrotra: CREW: A Gossip-based Flash-Dissemination System, *ICDCA '06* (2006).

- [11] Jay A. Patel, Indranil Gupta and Noshir Contractor:JetStream: probabilistic contour extraction with particles, *Computer Vision, 2001. ICCV '01* (2001).
- [12] Google:Google Storage for Developers, *Google I/O '10* (2010).
- [13] <http://aws.amazon.com/jp/s3/>:Amazon S3.
- [14] <http://www.microsoft.com/windowsazure/>:Windows Azure:Microsoft's Cloud Services Platform.